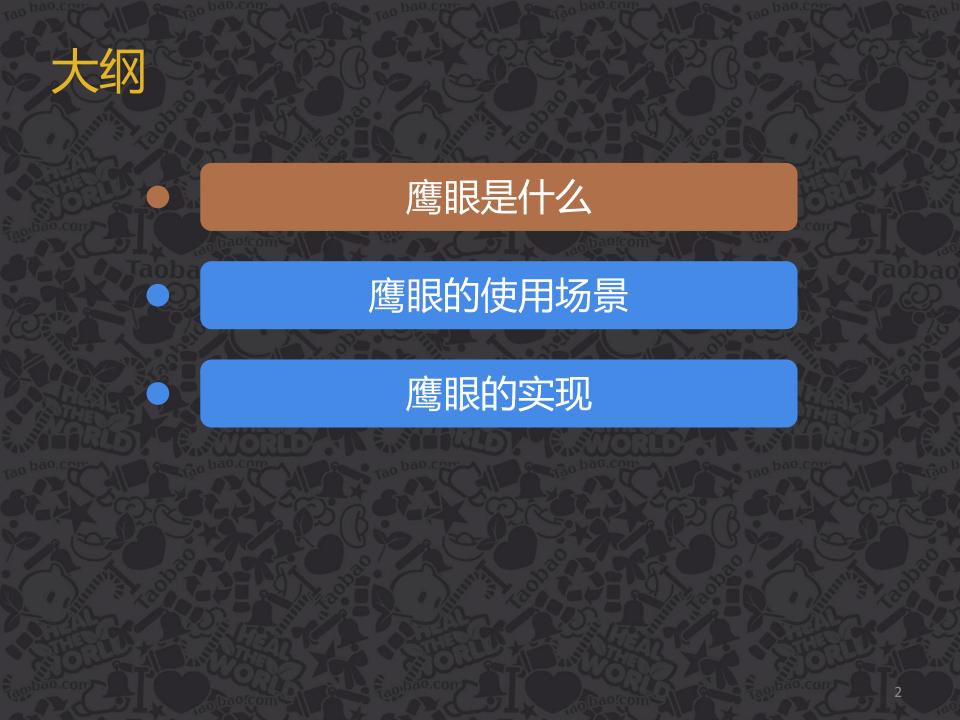


鹰眼下的淘宝

分布式调用跟踪系统介绍

淘宝网 司徒放 (姫风)

jifeng@taobao.com



现状

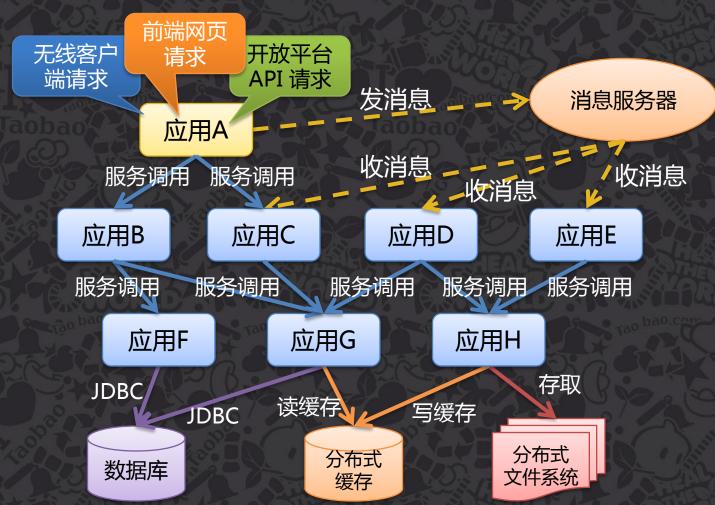


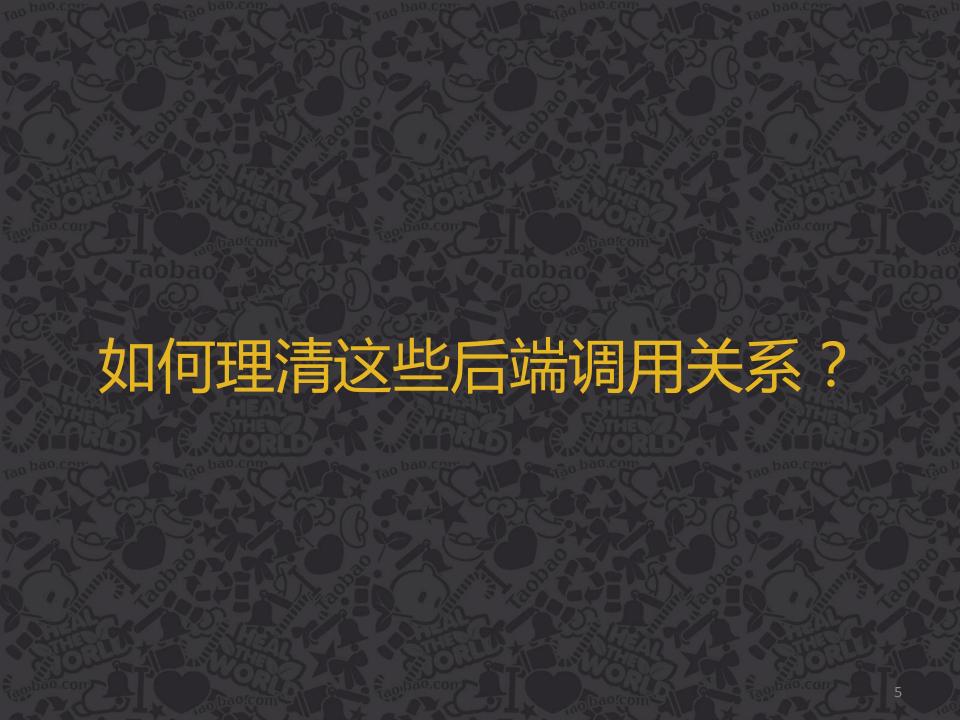
• 日趋复杂的分布式系统

- 远程服务调用
- 消息通讯
- 数据库分库分表
- 分布式缓存
- 分布式文件系统
- -

现状







举个例子



- 整个分布式系统
 - 高速公路网
- 前端请求
 - 高速上行驶的车辆
- 处理请求的应用
 - 高速上的收费站



举个例子



• 高速收费站将车辆通行信息记录成日志

[2013-05-01 12:23:34] 鲁A123BC,平度2,S16,济南,¥0

[2013-05-01 12:23:40] 鲁A987DE,平度2,S16,淄博,¥10

[2013-05-01 12:43:15] 鲁A123BC,潍坊1,S20,济南,¥18

[2013-05-01 13:38:29] 鲁A123BC,青州西1,G20,济南,¥10

[2013-05-01 13:38:30] 鲁A567AB,青州西2,G20,潍坊,¥10

[2013-05-01 14:39:27] 鲁A123BC,淄博3,G20,济南,¥15

[2013-05-01 16:42:58] 鲁A123BC,济南3,G20,济南,¥25

•••••

举个例子



• 可以分析车辆 鲁A123BC 的行驶路线

- [05-01 12:23:34] 平度2,旅途开始
 - \downarrow
- [05-01 13:38:29] 青州西1 , 耗时 75 分钟 , 路费 10 元 ↓
- [05-01 14:39:27] 淄博3,耗时 61 分钟,路费 5 元 ↓
- [05-01 16:42:58] 济南3, 耗时 123 分钟, 路费 10 元

简介



- 鹰眼 (Eagle Eye)
 - 基于日志的分布式调用跟踪系统
 - 脱胎于 Google Dapper 论文

- 核心:调用链。每次请求都生成一个全局唯一的ID(Traceld),通过它将不同系统的"孤立的"日志串在一起,重组还原出更多有价值的信息



简介

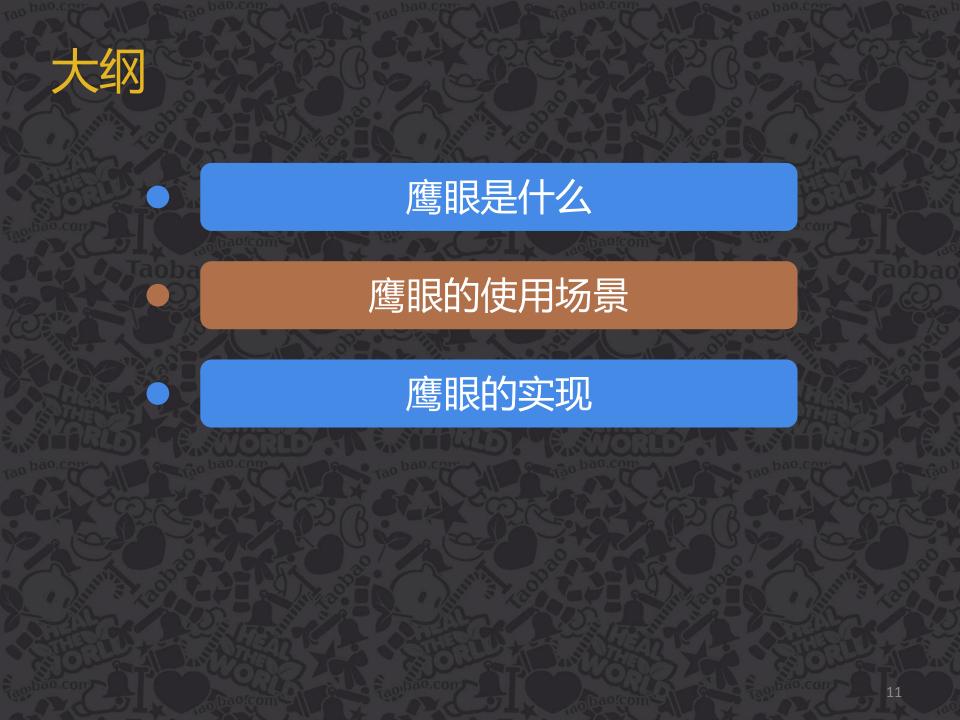


• 目前状况

每日调用链上1千亿,来自500多个前端,500多个后端应用, 还有数百个数据库、缓存、存储,分析的日志超过3千亿行

• 覆盖了淘宝主要的有网络通信的中间件

- ✓ 前端请求接入:Tengine(nginx)
- ✓ 分布式 Session: tbsession
- ✓ 远程服务调用框架 (RPC): HSF
- ✓ 异步消息通讯 (MQ): Notify
- ✓ 分库分表访问数据库 (JDBC): TDDL
- ✓ 分布式缓存 (memcache):Tair
- ✓ 分布式文件系统 (HDFS): TFS
- ✓ 特定功能的客户端,如搜索、支付等
- ✓ 其他中间件,如:HttpClient......







	9a7e137369807538429		:∃. 2012	07 10 14	47:55,384、迎用辩芦叶长。600mc。 日本原文		— ID —	rnaID
响用和					47:55.382. JAM NC 18:14-1 BIIIMBA H H H I		ID in	TPCID
, per	12707日	No. and	NAME OF THE PERSONS ASSESSED.	15.3	mo.4e ノエ-ソ がK73173744		H 3 1-9714	
0	■ buy	T RACE	OK	.2KB	tp://buy.taobao.com/auction/order/unity_order_confirm.htm			599ms
0.1	□ dolivery	ice	OK	11/0			41mc	
0.2	tee	HSF	OK	.9KE			5ms	
0.3	inventoryplatforr inventoryplat	HSF	OK	.3KE			2ms	
0.4	inventoryplatforr inventoryplat	HSF	OK	.6KE			3ms	
0.5	inventoryplatforr inventoryplat	HSF	OK	4.9KE			3ms	
0.6	inventoryplatforr inventoryplat	HSF	OK	.5KE			3ms	
0.7	inventoryplatforr inventoryplat	HSF	OK	4.5KE			3ms	
0.8	inventoryplatforr inventoryplat	HSF	OK	.5KE			3ms	
0.8.1	(db@tmall_inven		OK		In a particular account to the		1ms	
0.9	delivery	HSF	OK	3KE			32ms	
0.10	tradeplatform	HSF	OK	.3KE			2ms	
0.11	upp	HSF	OK	.9KE	an individual control of the control of		4ms	
0.12	delivery	HSF	OK	12.6K			4ms	
0.13	☐ tradeplatform	HSF	OK	4 9.0K	The second second second		96ms	
0.13.		N)TIF	OK	.5KE	region beginning that it was some part and		5ms	
0.14	tradeplatform	HSF	OK	.2KE			38ms	
0.15	tradeplatform	HSF	OK	.3KE			19ms	
0.16	★ tradeplatform	HSF	OK	.3KE			13ms	
0.17	tradeplatform	HSF	OK	.3KE			16ms	
0.18	tradeplatform	HSF	IZERR	100000000000000000000000000000000000000			14ms	
0.19	tradeplatform	HSF	OK	.3KE			14ms	
0.20	★ tradeplatform	HSF	OK	.3KE			12ms	
0.21	tradeplatform	HSF	OK	13.4K	The control of the control of		9ms	
0.22	□ tradeplatform	HSF	ОК	315B			22ms	
0.22.		N)TIF	OK	.2KE	makes the strong that the sea common terms		4ms	india:
0.23	■ tradeplatform	HSF	OK	1 1.2K	to the control of the control of		The state of the s	204ms
0.23.	(notify@trade)	N)TIF	OK	.3KF				ms
J.23 .	Tarrier State Control of the Control	N)TIF	OK					15ms
0.23.		N)TIF	OK					23ms
0.23.		AIR		50 100	Million Committee Committe			0ms
0.23.		AIR	OK	58B	Market Control of the			2ms
0.23.			OK	1,8KE				22ms
0.23.1			OK	1.8KE				15ms
0.23.		_	OK					1ms
0.23.		TO 000 100 100 100 100 100 100 100 100 10	OK	1.8KB				19ms
0.23.	. (db@notify t		OK			X		1ms
28	9 жили и.ж. , , , , , , , , , , , , , , , , , ,	>1115						



- 与异常监控集成
 - 排查问题需要查看 n 台机器的监控、日志? No!
 - 应用报异常或处理超时,在日志打印当前调用链 Traceld
 - 用 Traceld 查询调用链,定位问题
 - 把链路上下文抛出的异常堆栈关联起来
 - 把链路上的服务器 CPU Load、JVM、IO、网络状况关联起来



2013-07-20 05:25:28,179 ERROR taobao.hsf -

基于 RPC 协议调用服务

[com.taobao.wireless.trade.api.tmall.hsf.TmallBagInterface:1.0.0]的

[bulidConfirmOrder]方法时出现错误:

所调用的服务目标地址为:[...]

参数信息为:[...] Traceld=ac18287913742691251746923

错误原因为超时,请查看服务器端的执行日志是否也超时,执行时间为:3000

毫秒。

HSFTimeOutException

at com.taobao.hsf.....HSFResponseFuture.getResponse(HSFResponseFuture.java:52) at com.taobao.hsf.....SyncInvokeComponent.invoke(SyncInvokeComponent.java:51) at ...



监控系统从日志匹配异常堆栈和错误信息中的 Traceld Traceld=ac18287913742691251746923

応用名	IP 类型	状态	小	服务/方法	, and	
top	TRACE	OK		http://api.m.taobao.com/rest/api3.do		3
wiif	HSF	OK	8.5KB	the first of the same factor of the same factor.	3ms	
sirius	HSF	TIMEOUT	6.9KB	wireless. TmallBagInterface@bulidConfirmOrder~P		3
(tair@wireless)	TAIR	NOTEXSI	65B	The second contracts	1ms	
(tair@uic)	TAID	OK	570		0ms	-51
buyapi	HSF	OK	11.6KB	national contraction and process of the		3
сагсарі	пог	UK	2.400		3ms	ı
delivery	HSF	OK	844B		1ms	
tradeplatform	HSF	OK	1.3KB		2ms	
inventoryplatfo inventoryplatfo	HSF	OK	6.1KB		3ms	
inventoryplatfo inventoryplatfo	HSF	OK	8.9KB		3ms	
inventoryplatfo inventoryplatfo	HSF	OK	5.0KB		3ms	
delivery	HSF	OK	6.5KB		3ms	
dolivony	HCE	OK.	6 OVD		13ms	S
delivery	HSF	TIMEOUT	6.2KB	delivery.DeliveryTradeService@getItemsSupportPost~LL	4	38
(tair@1)	TAIR	CONNERR	3.7	GET:group_1:214		35
tradepiatromi	пэг	UK	/2/D			1
■ logisticscenter	HSF	OK	805B			3
ump	HSF	OK	13.6KB			1
delivery	HSF	OK	11.4KB			1
tradeplatform	HSF	OK	9.4KB			2
tradeplatform	HSF	OK	705B			2
tradeplatform	HSF	OK	815B			21

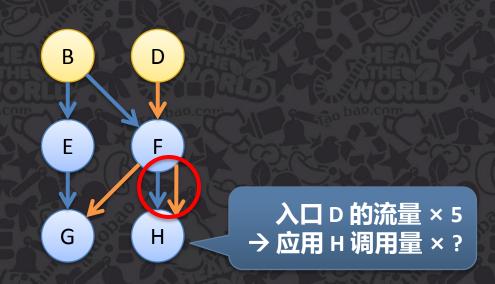


对多条调用链做统计和分析



• 容量规划

- 一般系统只统计对直接依赖的调用量
- 调用链可以得到对间接依赖、异步依赖的调用量



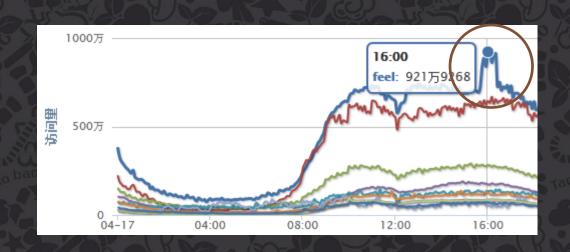


V		18 8 1000		1000	/S\V/	100	TX - Y	0 0/2			
层次	名称	应用	QPS	峰值 QPS	调用 次数		本地 耗时	依赖度	耗时 比例	标记	
根		-	118.13	269.64	1.0	435ms	51ms	100.0%	11.88%		Ф
1		-	226.02	483.12	1.94	8ms	8ms	98.51%	3.64%		ф
2		-	282.74	533.96	4.06	0ms	0ms	58.94%	0.02%		ф
2		-	74.41	170.57	1.77	0ms	0ms	35.56%	0.08%		ф
1		-	183.31	357.95	1.71	3ms	2ms	90.58%	1.0%		ф
2			182.59	356.96	1.71	0ms	0ms	90.28%	0.32%		ф
1		-	130.91	244.85	1.71	19ms	7ms	64.79%	1.98%		Ф
2		-	219.58	412.81	2.88	3ms	3ms	64.52%	1.37%		Ф
2		-	219.55	412.73	2.88	1ms	1ms	64.51%	0.45%		ф
2		-	131.28	243.79	1.72	0ms	0ms	64.51%	0.12%		Ф
2		-	125.25	231.11	1.7	0ms	0ms	62.2%	0.12%		Φ
1			124.27	230.45	1.1	25ms	19ms	96.07%	4.66%	强依赖	Ф
2			120.47	223.52	1.07	5ms	5ms	95.48%	1.3%		Ф
1		-	116.05	247.93	1.0	4ms	4ms	98.25%	1.05%		Ф
1			114.76	216.99	1.08	43ms	37ms	90.14%	8.28%	强依赖	Ф
1			113.49	214.98	1.0	5ms	5ms	96.08%	1.16%	强依赖	Ф
1			111.23	236.02	1.03	3ms	3ms	91.82%	0.68%	强依赖	Ф
1			111.2	208.29	1.05	13ms	13ms	89.46%	2.88%		Ф
1			110.24	213.12	1.0	214ms	207ms	93.32%	44.5%	瓶颈	ф
2			116.92	220.86	1.07	5ms	5ms	92.59%	1.28%		ф
1			106.5	205.27	1.0	3ms	3ms	90.16%	0.81%	19	ф

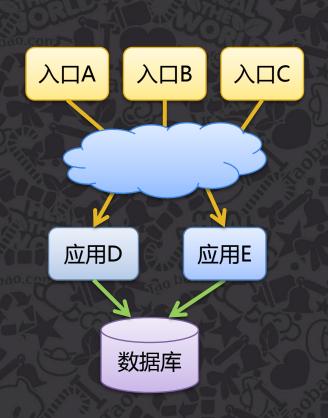


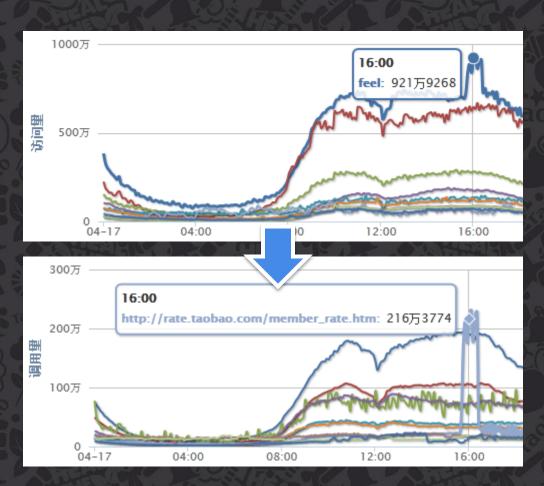
• 调用来源

- 后端数据库请求量突然上涨,需要排查请求来源











• 依赖度量

- 强依赖 & 弱依赖





• 依赖度量

- 强依赖 & 弱依赖





• 依赖度量

- 强依赖
 - 调用失败会直接中断主流程
- 高度依赖
 - 一次链路中调用某个依赖的 几率高
- 频繁依赖
 - 一次链路调用同一个依赖的 次数多



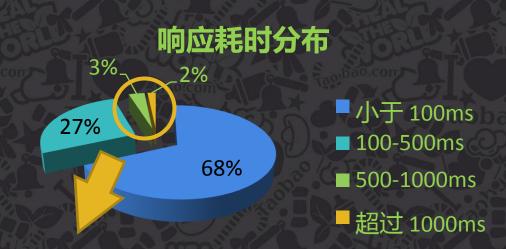


层次		应用	QPS	峰值	调用		本地	依赖度	耗时	标记	
				QPS	次数	耗时	耗时		高度	依赖	
根			<u> </u>	】	1.0	435ms	51ms	100.0%)
1			频繁体	父	1.94	8ms	8ms	98.51%	3.64%		Ф
2			282.74	533.96	4.06	0ms	0ms	58.94%	0.02%		Ф
2			74.41	170.57	1.77	0ms	0ms	35.56%	0.08%		Ф
1			183.31	357.95	1.71	3ms	2ms	90.58%	1.0%		Ф
2			182.59	356.96	1.71	0ms	0ms	90.28%	0.32%		Ф
1			130.91	244.85	1.71	19ms	7ms	64.79%	1.98%		Ф
2			219.58	412.81	2.88	3ms	3ms	64.52%	1.37%		Ф
2			219.55	412.73	2.88	1ms	1ms	64.51%	0.45%		Ф
2			131.28	243.79	1.72	0ms	0ms	64.51%	0.12%		Ф
2			125.25	231.11	1.7	0ms	0ms	62.2%	0.12%		Ф
1			124.27	230.45	1.1	25ms	19ms	96.07%	4.66%	强依赖	Ф
2			120.47	223.52	1.07	5ms	5ms	95.48%	强/	衣赖	Ф
1		-	116.05	247.93	1.0	4ms	4ms	98.25%	JAI		ф
1			114.76	216.99	1.08	43ms	37ms	90.14%	8.28%	强依赖	ф
1	1 Transfer or gave of the control of		113.49	214.98	1.0	5ms	5ms	96.08%	1.16%	强依赖	ф
1			111.23	236.02	1.03	3ms	3ms	91.82%	0.68%	强依赖	Ф
1			111.2	208.29	1.05	13ms	13ms	89.46%	2.88%		ф
1			110.24	213.12	1.0	214ms	207ms	93.32%	44.5%	瓶颈	Ф
2			116.92	220.	≠E:	— 寸瓶颈	s	92.59%	1.28%		Ф
1	AMBRUSKOUD SALVES SEE		106.5	205.2	Т БН	771171	s	90.16%	0.81%	25	Ф



• 调用耗时

- 瓶颈点
- 非正常的瓶颈
 - 弱依赖异常导致 主流程耗时过长

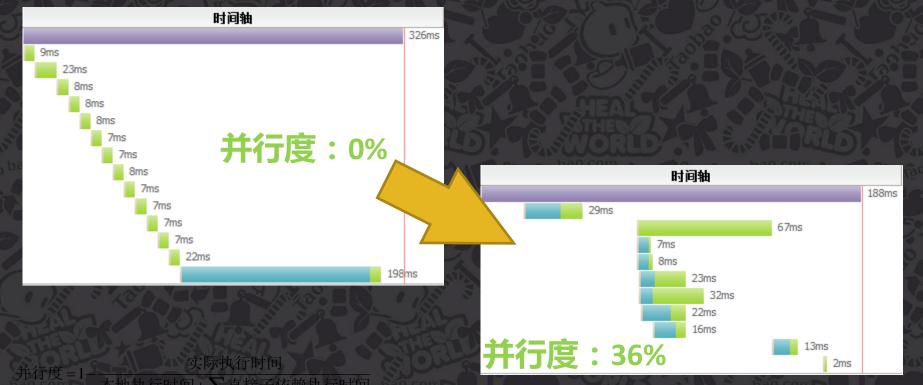


应用名	类型	状态	大小	服务/方法		时间轴
□ tmallbuy	TRACE	OK	-	http://buy.tmall.com/order/confirm_order.htm	1	3s130ms
tradeplatform	HSF	OK	1.3KB		3ms	
delivery	HSF	TIMEOUT	845B			3s8ms
itemcenter	HSF	OK	10.8KB			9ms
itemcenter	HSF	OK	3.5KB			4ms
■ pointcenter	HSF	OK	681B			2ms
memberplatform	HSF	OK	1.3KB			3ms
■ inventoryplatforr	HSF	OK	4.7KB			3ms
delivery	HSF	OK	7.0KB			7ms
⊞ maybach	HSF	OK	12.5KB			42ms
tradeplatform	HSF	OK	732B			1ms
delivery	HSF	OK	12.3KB			7ms
■ tradeplatform	HSF	ОК	3.3KB			18ms
tradeplatform	HSF	ОК	816B			1ms



• 调用并行度

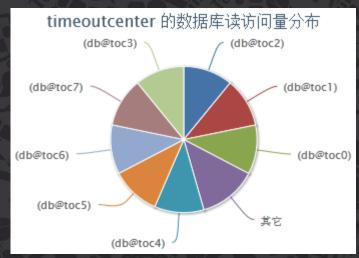
- 为链路并行、异步优化提供参考

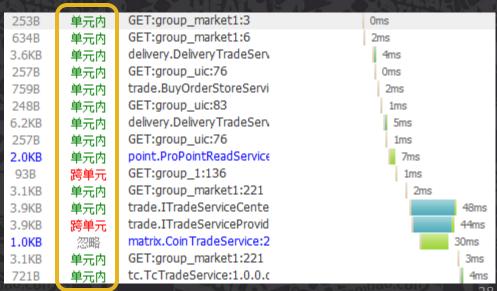




- 调用路由情况
 - 调用分布均衡性
 - 是否存在热点?

- 检验网络路由
 - 路由是否正常?
 - 网络是否封闭?





Tao bao. Carr.

3. 透明数据传输

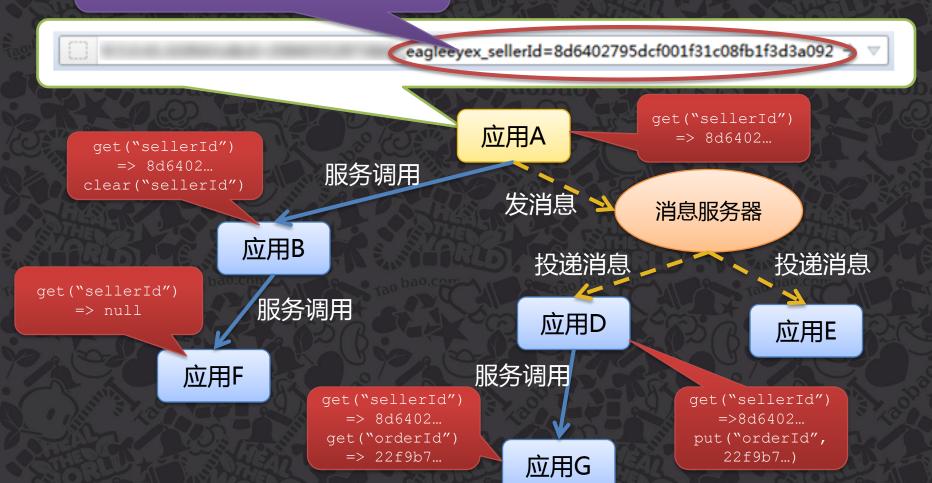


将业务数据与调用链集成

透明数据传输



eagleeyex sellerId



透明数据传输

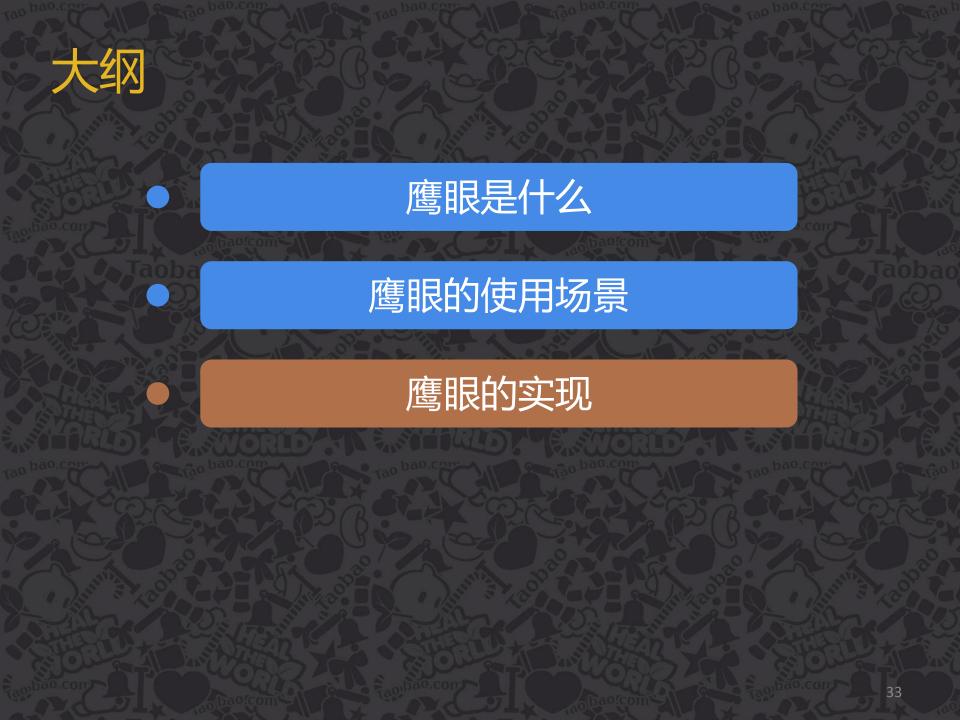


- 鹰眼自身需要传递 Traceld 等上下文信息
- 在调用链上透明传输业务数据
 - 调用路由控制
 - 传递特定环境的标识,用于调用路由判断
 - 调试指令
 - 在 URL 上设置调试指令,操纵后端服务
 - 前端网关特有的数据
 - 把前端应用特有的数据传到若干层后端的某个服务中

小结

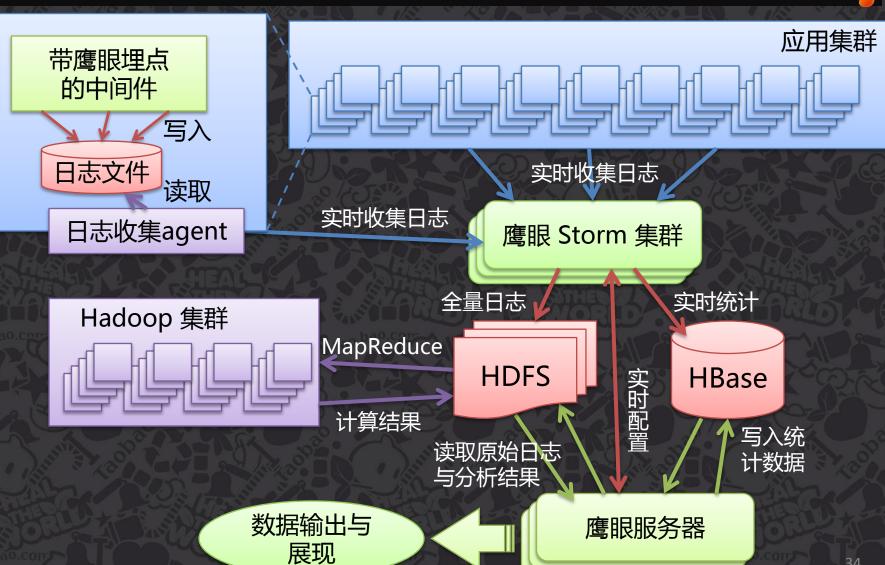


- 调用链跟踪
- 链路分析
- 透明数据传输



整体架构





整体实现介绍

Inobao Inobao

- 1. 埋点和输出日志
- 2. 收集和存储日志
- 3. 分析调用链

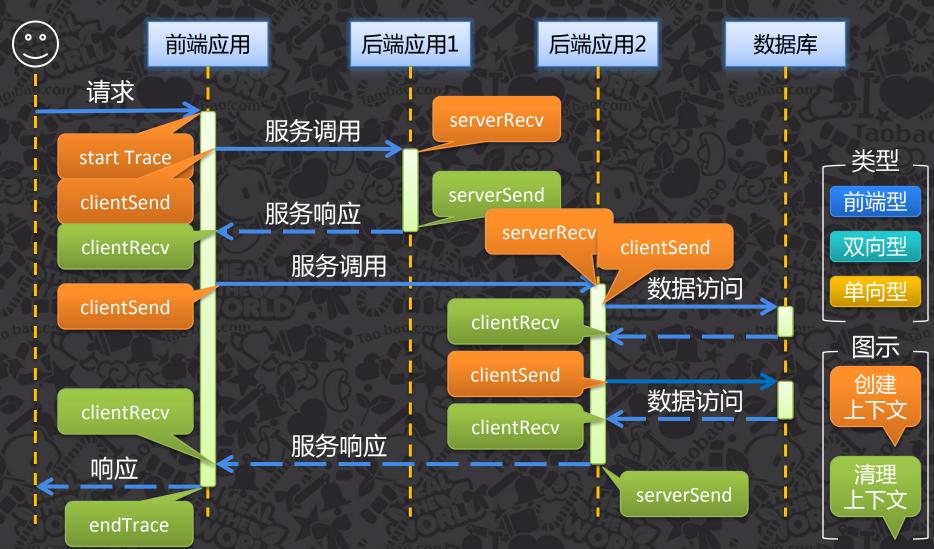
埋点和输出日志



• 如何埋点实现透传

- 在中间件创建调用上下文, 生成日志埋点
- 调用上下文放在本地 ThreadLocal, 对业务透明
- 调用上下文在中间件的网络请求中传递







• 做了哪些埋点

- Traceld、Rpcld、开始时间、调用类型、对端 IP
- 处理耗时
- 处理结果 (ResultCode)
- 传输量:请求大小/响应大小
- 与中间件相关的数据



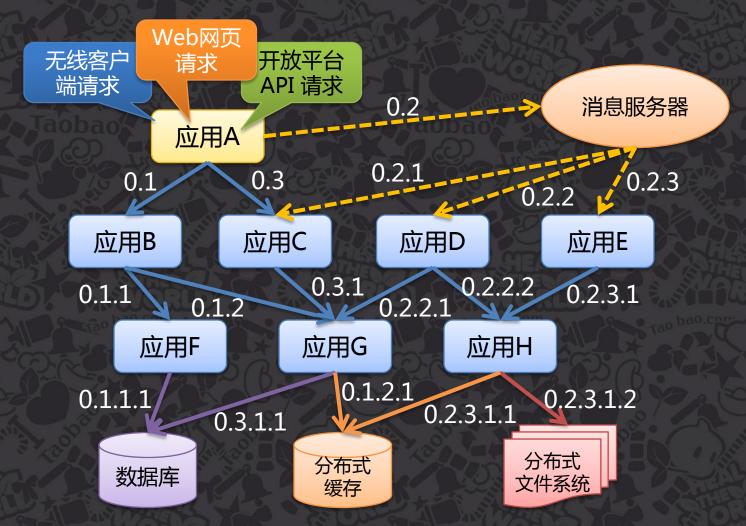
• 调用上下文: Traceld

- 关联一次请求相关的日志,全局唯一,在各个系统间 传递
- 是否需要业务语义?
 - IP 地址:在淘宝环境可直接映射到前端应用
 - 创建时间:在存储时用于分区
 - 顺序数:用于链路采样
 - 进程号:可选,单机多进程的应用使用
 - 标志位:可选,用于调试和标记



- 调用上下文: Rpcld
 - 标识日志埋点顺序和嵌套关系, 也在各个系统间传递
- 调用关系
 - 同步 / 异步 / 一对多调用
- 用什么方式实现 Rpcld 适合表示上述关系?
 - 顺序编号:1、2、3...
 - 多级编号: 0、0.1、0.2、0.2.1...







• 输出日志时面临的挑战

- 减少对业务线程的影响,降低资源消耗
- 每个网络请求至少1行日志, QPS 越高日志产生越快



- 解决方案:自己实现日志输出
 - 异步线程写日志
 - 对调用链做采样
 - 开关控制
 - 对服务等长字符串做编码
 - 日志输出缓存,限制 IO 次数,每秒刷新
 - 日志文件按大小滚动,自动清理
 - 统一字符编码,统一时区

整体实现介绍

Taobao

- 1. 埋点和输出日志
- 2. 收集和存储日志
- 3. 分析调用链

收集和存储日志



• 实时收集日志

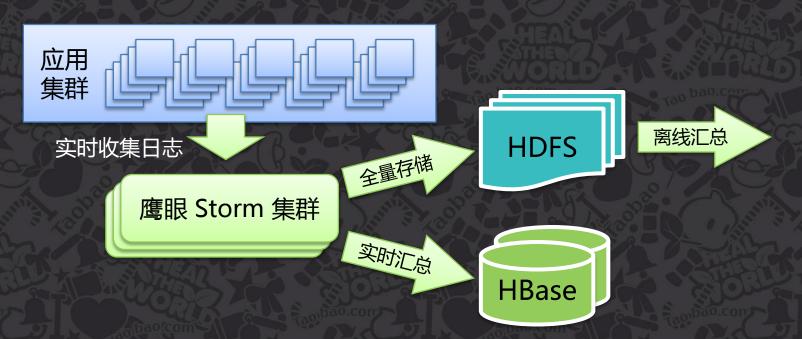
- 调用链的日志分散在调用经过的各个服务器上
- 离线分析需要将同一条调用链的日志汇总在一起

收集和存储日志



• 按 Traceld 汇总日志

- 基于数据库:用Traceld关联查询
- 基于 HBase: Traceld 做 rowkey,实时性强
- 基于 HDFS:顺序存储,后续 MapReduce 汇总



整体实现介绍

Taobao

- 1. 埋点和输出日志
- 2. 收集和存储日志
- 3. 分析调用链



- 基于入口对调用链做链路分析
 - 入口是调用链的源头
 - 同一个入口背后走的是同一套业务逻辑
 - 入口的多条调用链 → 入口链路
 - 如果业务代码没更新,链路的执行逻辑一般不会改变



• 离线分析

- 多条调用日志 汇总 (by Traceld)
- 还原调用关系 → 重组 (by Rpcld)
- 分析链路

• 实时分析

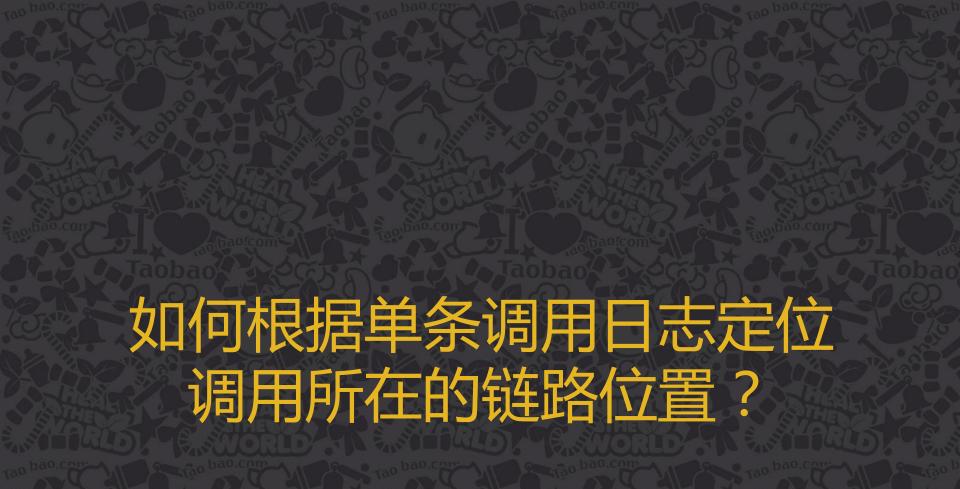
- 借助离线分析的产出,如链路形态、依赖情况等
- 对单条调用日志直接分析,不需要汇总、重组
- 得到链路上的调用情况,如 QPS、RT、错误情况

Tabbao

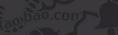
离线分析得到	实时分析回填
链路形态	调用数据

	离线	分	斤产	出		Taoba		
PS			言息		依赖度	耗时 比例	标记	
18.13	269.64	1.0	435ms	51ms	100.0%	11.88%		φ
26.02	483.12	1.94	8ms	8ms	98.51%	3.64%		ф
82.74	533.96	4.06	0ms	0ms	58.94%	0.02%		ф
4.41	170.57	1.77	0ms	0ms	35.56%	0.08%		Φ
83.31	357.95	1.71	3ms	2ms	90.58%	1.0%		ф
82.59	356.96	1.71	0ms	0ms	90.28%	0.32%		Φ
30.91	244.85	1.71	19ms	7ms	64.79%	1.98%		ф
19.58	412.81	2.88	3ms	3ms	64.52%	1.37%		ф
19.55	412.73	2.88	1ms	1ms	64.51%	0.45%		ф
31.28	243.79	1.72	0ms	0ms	64.51%	0.12%		ф
25.25	231.11	1.7	0ms	0ms	62.2%	0.12%		ф
24.27	230.45	1.1	25ms	19ms	96.07%	4.66%	强依赖	ф
20.47	223.52	1.07	5ms	5ms	95.48%	1.3%		ф
16.05	247.93	1.0	4ms	4ms	98.25%	1.05%		ф
14.76	216.99	1.08	43ms	37ms	90.14%	8.28%	强依赖	Φ
13.49	214.98	1.0	5ms	5ms	96.08%	1.16%	强依赖	Φ
11.23	236.02	1.03	3ms	3ms	91.82%	0.68%	强依赖	Φ
11.2	208.29	1.05	13ms	13ms	89.46%	2.88%		Φ
10.24	213.12	1.0	214ms	207ms	93.32%	44.5%	瓶颈	Ф
16.92	220.86	1.07	5ms	5ms	92.59%	1.28%		ф
06.5	205.27	1.0	3ms	3ms	90.16%	0.81%	52	Ф

	恨		
5	1	/	
N	2		
	2		
1	1		
1	2		
	1		
X.	2		
	2		
	2		
	2		
	1		
	2		
i	1		
	1		
1	1		
V	1		
	1		
	1		
N	2	1	





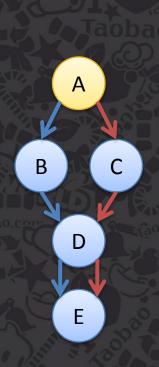




- Step1:定位入口链路
 - 入口应用:可以从 Traceld 隐藏的业务数据得到
 - 入口签名:每行日志都带的4字节ID
 - 在创建链路时生成,用于标识入口
- Step2:定位在链路中的具体位置
 - 链路签名:每行日志都带的4字节ID
 - 请求到达服务端时,在原签名上叠加当前签名



• 入口签名与链路签名的计算方法



链路层次	入口签名	链路签名
A	h(A)	
$A \rightarrow B$	h(A)	h(B)
$A \rightarrow C$	h(A)	h(C)
$A \rightarrow B \rightarrow D$	h(A)	h(B) * 31 + h(D)
$A \rightarrow C \rightarrow D$	h(A)	h(C) * 31 + h(D)
$A \rightarrow B \rightarrow D \rightarrow E$	h(A)	(h(B) * 31 + h(D)) * 31 + h(E)
$A \rightarrow C \rightarrow D \rightarrow E$	h(A)	(h(C) * 31 + h(D)) * 31 + h(E)

鹰眼的实现小结



1. 埋点和输出日志

- 中间件埋点,基于ThreadLocal
- 异步写,采样

2. 收集和存储日志

- 实时抓日志,按 Traceld 汇总,不同的存储方式

3. 分析调用链

- 基于入口的链路分析
- 实时分析:入口和链路签名

谢谢

淘宝网 司徒放 (姫风)

jifeng@taobao.com